



南开大学
Nankai University

计 算 机 学 院

大数据计算及应用实验报告

期末作业
Recommendation Systems

姓名：胡进喆 原敬闰 张明昆

学号：2213045 2211771 2211585

专业：计算机科学与技术 物联网工程

指导老师：杨征路

日期：2025 年 5 月 21 日

摘要

目录

1. 实验背景
2. 数据集说明
 2. 1. train.txt
 2. 2. test.txt
3. User-Based CF
 3. 1. 算法原理
 3. 1. 1. 用户相似度计算
 3. 1. 2. 评分预测
 3. 2. 代码实现
4. Item-Based CF

1. 实验背景

2. 数据集说明

我们编写 `data_analysis.py` 对数据集进行统计分析，得到如下结果：

2.1 train.txt

数据集概览为：

属性	数值	属性	数值
评分数量	90,854	用户数量	598
用户平均评分数量	151.93	物品数量	9,077
物品平均评分数量	10.01	用户ID范围	1~610
评分均值	69.88	数据集稀疏度	98.33%
评分标准差	20.78	物品ID范围	1~193609

从用户 ID 范围来看，最小用户 ID 为 1，最大用户 ID 为 610，表明**用户 ID 是连续且紧密分布的**。物品 ID 范围从 1 到 193609，呈现出较大的跨度，与物品数量（9077）对比，**说明物品 ID 存在明显不连续的情况**。每个用户的平均评分数量为 151.93 条，表明数据集中用户参与评分的活跃度较高。反观物品维度，平均每个物品仅获得约 10.01 个评分。这揭示了物品的受欢迎程度分布不均，多数物品可能仅获得少数用户关注，长尾效应显著，部分冷门物品的评分稀缺可能影响推荐算法对这些物品的准确评估。

评分的均值为 69.88，标准差为 20.78，表明评分数据整体上呈现出较为集中的趋势，但也有一定程度的波动。从分位数来看，中位数为 70，25% 分位数为 60，75% 分位数为 80。这暗示着评分分布**可能呈现出一定的正偏态**，即多数评分集中在中高分段，低分段的评分数量相对较少。

评分稀疏度高达 0.9833，即数据矩阵中约 98.33% 的位置是空缺的，**这在推荐系统中属于非常高的稀疏度水平**，给模型训练带来了极大的挑战，需要采用有效的矩阵填充或降维方法。

下表展示了各评分值的出现频率：

评分值	出现次数	评分值	出现次数
10	1221	60	18119
20	2552	70	11996
30	1603	80	24177
40	6852	90	7742
50	5067	100	11525

从上表可以看出，**高分值（如 60、80、100）的出现频率明显高于低分值**。评分 80 出现次数最多，达到 24177 次，占总评分数的约 26.6%，而评分 10 的出现次数最少，仅占约 1.34%。这种评分分布表明用户在评分时更倾向于给出中高分评价，可能反映出数据集整体质量较高，或者存在用户评分偏乐观的倾向。

2.2 test.txt

3. User-Based CF



此部分为胡进喆单独完成

协同过滤推荐（Collaborative Filtering recommendation）是在信息过滤和信息系统中正迅速成为一项很受欢迎的技术。与传统的基于内容过滤直接分析内容进行推荐不同，协同过滤分析用户兴趣，在用户群中找到指定用户的相似（兴趣）用户，综合这些相似用户对某一信息的评价，形成系统对该指定用户对此信息的喜好程度预测。协同过滤算法主要分为**基于启发式和基于模型式两种**。其中，基于启发式的协同过滤算法，又可以分为基于用户的协同过滤算法（User-Based）和基于项目的协同过滤算法（Item-Based）。**

3.1 算法原理

User-Based协同过滤 (User-Based Collaborative Filtering, 简称User-Based CF) 是一种基于群体智慧的核心推荐方法, 其思想源于“相似用户可能对未交互项目具有相近的偏好”。该方法通过分析用户历史行为数据, 挖掘用户间的相似性关系, 并利用相似用户对目标项目的评分来预测目标用户的潜在兴趣。具体原理可分为以下三个关键环节:

User-Based CF的输入依赖于用户对项目的显式或隐式反馈数据。显式反馈 (主动评分) 包括用户直接对商品、电影等项目的评分或评价, 而隐式反馈 (被动评分) 则通过用户行为 (如购买记录、浏览时长、点击率) 间接反映兴趣强度。例如, 电子商务场景中, 用户的购买行为天然构成隐式评分矩阵, 其中购买频次或金额可量化为评分值。这些数据被组织为用户-项目评分矩阵, 矩阵中的每个元素 $R_{u,i}$ 表示用户 u 对项目 i 的评分, 未评分的项目则作为待预测目标。

3.1.1 用户相似度计算

核心假设是相似用户对同一项目的评分具有一致性。为此, 需定义用户间相似性度量方法, 常见算法包括:

皮尔逊相关系数 衡量两位用户评分趋势的线性相关性, 通过消除用户评分尺度偏差 (如部分用户习惯性打高分或低分) 提升相似度准确性。公式为:

$$\sin(u, v) = \frac{\sum_{i \in I_{uv}} (R_{u,i} - \bar{R}_u)(R_{v,i} - \bar{R}_v)}{\sqrt{\sum_{i \in I_{uv}} (R_{u,i} - \bar{R}_u)^2} \sqrt{\sum_{i \in I_{uv}} (R_{v,i} - \bar{R}_v)^2}}$$

- 其中, I_{uv} 为用户 u 与 v 共同评分的项目集合, $\bar{R}_u$ 、 $\bar{R}_v$ 为各自的平均评分。皮尔逊系数范围在 $[-1, 1]$, 值越大表示用户偏好越相似。

余弦相似度 将用户评分视作向量, 计算其夹角的余弦值以衡量方向相似性, 适合处理稀疏数据。公式为:

$$\sin(u, v) = \frac{\sum_{i \in I_{uv}} R_{u,i} \cdot R_{v,i}}{\sqrt{\sum_{i \in I_{uv}} R_{u,i}^2} \cdot \sqrt{\sum_{i \in I_{uv}} R_{v,i}^2}}$$

- 调整后的余弦相似度进一步考虑项目平均评分, 消除热门项目的高评分偏差, 公式中每个评分减去对应项目的平均分 $\bar{R}_i$ 。

选择相似度方法需结合数据特性: 若用户评分存在明显尺度差异 (如严格型与宽容型用户), 皮尔逊系数更优; 若需快速处理高维稀疏数据, 余弦法更为高效。

3.1.2 评分预测

确定目标用户 u 的最近邻集合 $N(u)$ (即相似度最高的 k 个用户) 后, 预测其对未评分项目 i 的兴趣分值。预测公式为加权平均:

$$\hat{R}_{u,i} = \bar{R}_u + \frac{\sum_{v \in N(u)} \sin(u, v) \cdot (R_{v,i} - \bar{R}_v)}{\sum_{v \in N(u)} |\sin(u, v)|}$$

- 此公式通过引入用户平均评分 $\bar{R}_u$ 、 $\bar{R}_v$ 消除个体评分偏差, 并利用相似度作为权重, 强调高相似用户的评分影响。最终, 系统按预测分值降序推荐Top-N项目给用户。

User-Based CF的优势在于直观性强, 能够发现长尾项目, 但面临计算复杂度高 (用户数远大于项目数)、冷启动 (新用户数据稀疏) 等挑战。其适用于用户规模相对稳定、用户行为数据丰富的场景 (如电商、社交平台), 尤其在隐式反馈场景中, 通过行为日志构建评分矩阵, 可有效捕捉用户偏好动态变化。

3.2 代码实现

4. Item-Based CF